

Credit Risk Scoring Engine: Spain Market

Technical Documentation & Financial Impact Report

AUTOR

Rubén Montaña Camacho

Economist & Data Scientist

FECHA

Mayo 2026

Resumen

El presente informe técnico aborda el diseño, entrenamiento y puesta en producción de un sistema avanzado de *scoring* bancario destinado a la gestión del riesgo de crédito en el sector de préstamos *Peer-to-Peer* (P2P). Utilizando el conjunto de datos histórico de la plataforma Bondora para el mercado español, se desarrolla un modelo predictivo basado en el algoritmo de potenciación de gradiente CatBoost. La investigación se justifica ante la necesidad de las instituciones financieras modernas de migrar desde sistemas de puntuación tradicionales hacia arquitecturas de aprendizaje automático capaces de capturar interacciones no lineales complejas en el comportamiento del prestatario.

La metodología comprende un riguroso preprocesamiento de datos, incluyendo la ingeniería de características, la gestión de valores ausentes y el tratamiento del desequilibrio de clases. Se prioriza la estabilidad del modelo frente a la endogeneidad temporal, garantizando predicciones robustas de la Probabilidad de *Default* (PD). Un pilar fundamental del proyecto es la implementación de Inteligencia Artificial Explicable (XAI) mediante el uso de valores SHAP (*SHapley Additive exPlanations*). Esta técnica permite desmitificar la naturaleza de "caja negra" del algoritmo, proporcionando una trazabilidad completa de los factores que influyen en cada decisión de crédito, tales como la edad, el historial de pagos y el nivel educativo, cumpliendo así con las crecientes exigencias regulatorias de transparencia y ética algorítmica.

Los resultados demuestran una capacidad discriminativa moderada-alta y una calibración de probabilidades óptima para la estratificación de *ratings* de riesgo. El trabajo concluye que la integración de CatBoost y técnicas de interpretabilidad local no solo mejora la precisión técnica del *scoring*, sino que fortalece la confianza institucional en la concesión automatizada de activos financieros.

Palabras clave: Riesgo de Crédito, *Scoring* Bancario, *machine learning*, CatBoost, SHAP.

Summary

This technical report details the development, training, and deployment of an advanced banking scoring system for credit risk management in the Peer-to-Peer (P2P) lending sector. Using the historical dataset from the Bondora platform for the Spanish market, a predictive model based on the CatBoost gradient boosting algorithm is developed. The research is justified by the need for modern financial institutions to migrate from traditional scoring systems toward machine learning architectures capable of capturing complex non-linear interactions in borrower behavior.

The methodology encompasses rigorous data preprocessing, including feature engineering, missing value management, and class imbalance treatment. Model stability is prioritized over temporal endogeneity, ensuring robust predictions of the Probability of Default (PD). A fundamental pillar of the project is the implementation of Explainable Artificial Intelligence (XAI) using SHAP (SHapley Additive exPlanations) values. This technique allows for the demystification of the "black box" nature of the algorithm, providing complete traceability of the factors influencing each credit decision, such as age, payment history, and educational level, thereby meeting increasing regulatory demands for transparency and algorithmic ethics.

The results demonstrate a moderate-high discriminatory capacity and optimal probability calibration for risk rating stratification. The study concludes that the integration of CatBoost and local interpretability techniques not only improves the technical accuracy of scoring but also strengthens institutional confidence in the automated granting of financial assets.

Keywords: Credit Risk, Bank Scoring, machine learning, CatBoost, SHAP.

Índice de Contenidos

Resumen	2
Índice de Contenidos	4
Índice de Tablas	4
Índice de Acrónimos	5
Capítulo 1. Introducción	6
Capítulo 2. Motivación del trabajo	7
Capítulo 3. Objetivos del trabajo	8
Capítulo 4. Estado del arte del trabajo	9
4.1. La superación de la Regresión Logística en plataformas P2P	9
4.2. El dominio de los algoritmos basados en árboles (Gradient Boosting)	9
4.3. El reto regulatorio y la irrupción de la explicabilidad (XAI)	9
Capítulo 5. Base de datos del trabajo	11
5.1. Descripción del <i>dataset</i> de Bondora	11
5.2. Filtrado, limpieza y definición de la variable objetivo	12
5.3. Análisis Exploratorio de Datos (EDA)	12
5.4. Ingeniería de Variables (Ratios financieros)	14
5.5. Auditoría de fuga de datos (<i>Data Leakage</i>) y variables endógenas	15
5.6. Diccionario de Datos Final	16
Capítulo 6. Metodología empleada	18
6.1. Definición del <i>Benchmark</i> (El modelo original de Bondora)	19
6.2. Modelo Tradicional (Regresión Logística)	19
6.3. Modelo Avanzado (CatBoost)	19
6.4. Metodología de Interpretabilidad (XAI - SHAP)	20
6.5. Diseño del <i>Stress Testing</i> Macroeconómico	20
6.6. Evaluación del Rendimiento Algorítmico y Optimización Teórica	20
6.7. La Paradoja de la Selección Adversa en Mercados <i>Subprime</i>	21
Capítulo 7. Resultados y discusión	22
7.1. Evaluación del Rendimiento Predictivo	22
7.1.1. Capacidad de Discriminación General (ROC-AUC)	22
7.1.2. Métricas regulatorias de Riesgo de Crédito: Coeficiente de Gini y Estadístico KS	24

7.1.3. Validación de la Calibración de Probabilidades	24
7.2. Transparencia Algorítmica e Interpretabilidad Global (SHAP Summary Plot)	26
7.2.1. Interpretabilidad Global: Motor de Decisión (SHAP Summary Plot)	26
7.2.2. Interpretabilidad Local: Auditoría Individual de Expedientes	28
7.3. Optimización y Calibración del Umbral de Decisión (Cut-off)	30
7.3.1. Escenario de Estrés: Mitigación de Pérdidas Capitales (Umbral 9%)	30
7.3.2. Escenario Operativo: Optimización por Margen de Rentabilidad (Umbral 26%)	30
7.4. Simulación de Impacto Económico: Análisis de Clasificación	31
7.4.1. Evaluación del Comportamiento en Escenarios de Riesgo	31
7.4.2. Cuantificación del Valor Económico Añadido	32
7.5. Sistema de Clasificación Interna (Ratings) y Estratificación del Riesgo	33
7.5.1. Arquitectura de Segmentación	33
7.5.2. Distribución Empírica de la Cartera	34
7.5.3. Aproximación al Precio Técnico (Risk-Based Pricing)	35
7.5.4. Análisis de la Eficiencia en la Clasificación y Selección del Riesgo	36
7.6. Stress Testing Macroeconómico y Análisis de Sensibilidad	36
7.6.1. Diseño del Escenario de Crisis Severa	37
7.6.2. Análisis de la Migración de Cartera y Cortafuegos de Riesgo	37
Capítulo 8. Conclusiones	39
8.1. Superioridad Analítica y Resolución del Sesgo Geográfico	39
8.2. Transparencia y Explicabilidad (XAI)	39
8.3. Optimización Económica y Rentabilidad de Negocio	39
8.4. Resiliencia ante Escenarios de Crisis (Stress Testing)	40
8.5. Limitaciones del Estudio	40
8.6. Síntesis Final y Valor de la Propuesta	42
Capítulo 9. Trabajos futuros	43
Capítulo 10. Referencias Bibliográficas	45

Índice de Tablas

Tabla 1 Diccionario Analítico de las Variables Predictoras Fundamentales del Modelo -----	16
Tabla 2 Estructura de la Cartera de Validación y Distribución de Clientes por Tramo de Riesgo-----	34
Tabla 3 Aproximación al Precio Técnico y Estructura de Primas de Riesgo Mínimas por Niveles de <i>Rating</i> -----	35

Índice de Figuras

Figura 1 Distribución de la Variable Objetivo en la Cartera de Préstamos de Bondora -----	13
Figura 2 Matriz de Correlación Lineal de Pearson para el Análisis Exploratorio de Datos	14
Figura 3 Diagrama de Flujo de la Metodología y Arquitectura del Modelo Analítico-----	18
Figura 4 Curva ROC y Comparación del Rendimiento Predictivo entre CatBoost y el Modelo <i>Benchmark</i> -----	23
Figura 5 Curva de Kolmogorov-Smirnov para la Evaluación del Poder Discriminante del Algoritmo-----	24
Figura 6 Curva de Calibración y Fiabilidad en la Proyección de Probabilidades de Impago	25
Figura 7 Auditoría de Impacto Global y Dirección Predictiva de las Variables mediante Valores SHAP-----	27
Figura 8 Análisis de Interpretabilidad Local y Atribución de Riesgo para un Expediente Individual-----	29
Figura 9 Curva de Optimización del Umbral de Decisión y Minimización del Coste Financiero-----	31
Figura 10 Comparativa de Matrices de Confusión: Escenario de Estrés (9%) frente a Escenario Operativo (26%)-----	32
Figura 11 Impacto del Escenario Macroeconómico Adverso sobre la Distribución del Riesgo de la Cartera-----	37

Índice de Acrónimos

AUC: *Area Under the Curve* (Área Bajo la Curva)

DTI: *Debt-to-Income* (Ratio Deuda-Ingreso)

EDA: *Exploratory Data Analysis* (Análisis Exploratorio de Datos)

GDPR: *General Data Protection Regulation* (Reglamento General de Protección de Datos)

KS: Estadístico de Kolmogorov-Smirnov

LGD: *Loss Given Default* (Severidad de la Pérdida)

LR: *Logistic Regression* (Regresión Logística)

P2P: *Peer-to-Peer* (Red de Pares)

PD: *Probability of Default* (Probabilidad de Impago)

PR: *Precision-Recall* (Precisión-Exhaustividad)

PSD2: *Payment Services Directive 2* (Segunda Directiva de Servicios de Pago)

PTI: *Payment-to-Income* (Ratio Cuota-Ingreso)

ROC: *Receiver Operating Characteristic* (Característica Operativa del Receptor)

SHAP: *SHapley Additive exPlanations*

SMOTE: *Synthetic Minority Over-sampling Technique* (Técnica de Sobremuestreo Sintético de Minorías)

TAE: Tasa Anual Equivalente

XAI: *Explainable Artificial Intelligence* (Inteligencia Artificial Explicable)

Capítulo 1. Introducción

El riesgo de crédito es uno de los pilares fundamentales para que cualquier institución financiera sea viable a largo plazo. Tradicionalmente en la concesión de préstamos, la predicción de probabilidad de impago (*Probability of Default*) la han calculado los bancos usando modelos estadísticos clásicos. De hecho, la normativa de Basilea (Basel Committee on Banking Supervision, 2010), que es el marco normativo internacional que obliga a los bancos a tener un colchón de capital según el riesgo de sus clientes, exige que las decisiones matemáticas detrás de las concesiones o rechazos de los préstamos sean explicables. Bajo esta restricción, las entidades financieras decidieron de manera unánime que la Regresión Logística era el mejor modelo estadístico para aplicar, por lo que ha sido el estándar de la industria durante décadas.

Durante años este sistema tradicional era el mejor método disponible, pero debido al auge tecnológico el mercado financiero ha cambiado por completo. Muchos usuarios que no encajaban en los rígidos requisitos y estándares de la banca tradicional empezaron a buscar otras vías de financiación, de forma que nacieron las empresas y plataformas *Fintech*, que como su nombre indica, buscan conectar el mundo financiero y el tecnológico. Un claro ejemplo son los servicios de préstamos *Peer-to-Peer* (P2P), un modelo alternativo que conecta directamente a inversores particulares con personas que necesitan crédito, sin pasar por un banco. Dado que estas plataformas absorben a usuarios rechazados por la banca comercial, operan intrínsecamente en un mercado de alto riesgo (conocido financieramente como mercado *Subprime* o *High-Yield*), donde la alta probabilidad de impago se compensa con elevadas tasas de interés.

Sin embargo, con el crecimiento exponencial de la digitalización, las herramientas matemáticas clásicas de los bancos no son capaces de obtener el máximo rendimiento posible, ya que están ignorando factores y variables que pueden ayudar a mejorar la precisión de los modelos y consecuentemente el beneficio esperado. Según investigaciones recientes (Noriega et al., 2023), hay dos motivos principales para tener que actualizar los sistemas de Scoring: por un lado, la enorme cantidad de datos digitales y de comportamiento que generan estas plataformas; y por otro, que los métodos tradicionales se quedan cortos para analizar perfiles de clientes que muchas veces no tienen un historial crediticio previo.

En este escenario altamente competitivo, la supervivencia de las principales plataformas europeas del sector depende directamente de saber clasificar de forma precisa a los clientes solventes frente a los que van a impagar (Mondal y Shah, 2023). Por eso, en este Trabajo Fin de Máster proponemos dar un salto tecnológico y utilizar datos recientes y reales españoles para aplicar modelos de *machine learning* (en concreto, Gradient Boosting) que mejoren este modelo tradicional de predicción. Además, para no perder la explicabilidad que exige la normativa financiera, aplicaremos técnicas de Inteligencia Artificial Explicable (XAI) para poder entender y justificar cómo toma las decisiones el algoritmo en todo momento.

Capítulo 2. Motivación del trabajo

El origen de este Trabajo Fin de Máster nace de una motivación muy clara: conectar el mundo de la economía, que a menudo se relaciona con una disciplina rígida o excesivamente teórica, con las herramientas tecnológicas que tanto se han desarrollado durante los últimos años. En el mundo financiero clásico, medir el riesgo de que un cliente no devuelva un préstamo (el *scoring* bancario) se ha hecho siempre con modelos estadísticos muy conservadores. Sin embargo, al adentrarme en la Ciencia de Datos, vi la enorme oportunidad que existe para modernizar este proceso.

Esta idea es precisamente la que justifica el título que he seleccionado para el proyecto. Mi objetivo es desarrollar un modelo predictivo mediante *machine learning* para la concesión de crédito en España, pero complementándolo con el uso de Inteligencia Artificial Explicable (XAI) para así cumplir con las rigurosas normativas bancarias europeas.

El contexto en el que se desarrolla este trabajo es el de las plataformas de préstamos alternativos (P2P), un sector que ha crecido muchísimo pero que, debido a su novedad, comete errores graves. Un problema real es que estas empresas entrenan sus algoritmos con datos de clientes de países nórdicos o centroeuropeos y luego aplican esa misma regla matemática a usuarios de países como España. Esto genera un sesgo crítico (fenómeno conocido como *Concept Drift*) porque la realidad económica de ambos perfiles no tiene nada que ver, lo que acaba disparando la morosidad y las pérdidas de la empresa crediticia. La originalidad de este TFM radica justamente ahí: en crear un modelo de riesgo adaptado a España, que sea más preciso que los tradicionales y que, además, no sea un algoritmo opaco, ya que en la industria financiera actual sería ilegal basar las decisiones de crédito en predicciones opacas. Gracias a la explicabilidad, podremos entender y justificar financieramente por qué el algoritmo aprueba o deniega cada crédito.

Por otro lado, este trabajo es el escenario perfecto para aplicar de forma práctica e integrada lo que hemos visto durante el máster. Desde las primeras fases del proyecto, materias como Preparación y Transformación de Datos y Análisis de Datos han sido fundamentales para entender la base histórica, limpiar valores atípicos y detectar a tiempo errores graves de diseño como la fuga de información (*Data Leakage*). Posteriormente, el núcleo técnico del TFM se ha construido sobre los pilares de Análisis Estadísticos y Modelos Lineales y Aprendizaje Automático Aplicado, lo que me ha permitido enfrentar el estándar del sector (la Regresión Logística) contra un algoritmo mucho más potente basado en árboles de decisión (Gradient Boosting). Finalmente, para resolver la opacidad del modelo, los conceptos de Presentación y Visualización han sido clave para interpretar las predicciones mediante la metodología SHAP, generando gráficos claros que explican de forma visual qué peso tiene cada variable en la decisión final del algoritmo.

Capítulo 3. Objetivos del trabajo

El objetivo principal de este Trabajo Fin de Máster es desarrollar, validar e interpretar un modelo predictivo de *scoring* bancario para el mercado español utilizando técnicas de *machine learning*, garantizando la transparencia de sus decisiones mediante Inteligencia Artificial Explicable (XAI) para optimizar la gestión del riesgo de crédito.

Para alcanzar este objetivo general de manera estructurada, el proyecto se divide en las siguientes metas concretas, las cuales guiarán el desarrollo práctico del documento y sentarán las bases para las conclusiones:

- Auditar y depurar la base de datos histórica: Realizar una limpieza exhaustiva de la información inicial, tratando los valores nulos o atípicos y eliminando aquellas variables que contengan información del futuro para evitar la fuga de datos (*Data Leakage*).
- Crear nuevas variables de negocio (*Feature Engineering*): Diseñar e implementar ratios financieros y de endeudamiento que enriquezcan la información disponible y ayuden a los algoritmos a detectar mejores patrones de riesgo en los clientes.
- Establecer un *benchmark* de rendimiento algorítmico: Entrenar y comparar las métricas de acierto de un modelo estadístico clásico (Regresión Logística) frente a un algoritmo avanzado basado en árboles de decisión (Gradient Boosting).
- Garantizar la interpretabilidad del modelo óptimo: Aplicar la metodología matemática SHAP para interpretar las predicciones del mejor modelo, identificando qué peso tiene cada variable y asegurando que las decisiones cumplen con las exigencias de transparencia y auditoría del sector bancario.
- Cuantificar el impacto económico real: Calcular el ahorro financiero y el impacto en negocio que tendría la aplicación de este nuevo modelo predictivo en una cartera de préstamos simulada bajo condiciones normales.
- Evaluar la resiliencia de la cartera (*Stress Testing*): Someter el modelo de riesgo a escenarios macroeconómicos adversos (simulando contracciones de ingresos o aumentos de deuda en los clientes) para comprobar su robustez ante posibles crisis económicas, en línea con las exigencias regulatorias internacionales.

Capítulo 4. Estado del arte del trabajo

La literatura académica sobre la evaluación del riesgo de crédito ha experimentado una transformación radical en la última década, pasando de la validación de modelos estadísticos paramétricos a la optimización de algoritmos de *machine learning* y la interpretabilidad algorítmica, especialmente en el ámbito de los préstamos alternativos (P2P).

4.1. La superación de la Regresión Logística en plataformas P2P

Históricamente, la Regresión Logística (LR) ha sido el estándar normativo debido a su facilidad de interpretación (Thomas et al., 2002). Sin embargo, en el contexto del *crowdlending*, donde los prestatarios a menudo carecen de un historial bancario tradicional, la literatura reciente demuestra que la LR es insuficiente. En un estudio exhaustivo sobre plataformas P2P, Xia et al. (2018) demostraron que los modelos de *machine learning* superan consistentemente a la estadística tradicional al ser capaces de capturar relaciones no lineales complejas entre el comportamiento del usuario y la probabilidad de impago. En esta misma línea, Serrano-Cinca y Gutiérrez-Nieto (2016) ya advertían en sus ensayos pioneros que el éxito en estas plataformas no depende solo de evaluar la morosidad, sino de predecir la rentabilidad real ajustada al riesgo, algo que los modelos lineales no logran optimizar con precisión.

4.2. El dominio de los algoritmos basados en árboles (Gradient Boosting)

A medida que la investigación ha avanzado, el consenso académico se ha decantado por una familia específica de algoritmos para el análisis de datos financieros en formato tabular: los ensamblados de árboles de decisión. Autores como Moscatelli et al. (2020) evaluaron diversas arquitecturas de Inteligencia Artificial en el entorno bancario europeo, concluyendo que los modelos de Gradient Boosting (como XGBoost o LightGBM) superan tanto a las Redes Neuronales como a los Random Forest en la detección de impagos, debido a su mayor resistencia al sobreajuste (*overfitting*).

Más recientemente, la literatura ha puesto el foco en la variante CatBoost, introducida por Prokhorenkova et al. (2018). Investigaciones aplicadas al riesgo de crédito (Hancock y Khoshgoftaar, 2020) han destacado que CatBoost presenta una ventaja competitiva crucial: su algoritmo interno procesa variables categóricas (como el tipo de contrato, el género o el nivel educativo) de forma nativa, evitando la pérdida de información y la creación masiva de columnas vacías que exigen otros algoritmos mediante *One-Hot Encoding*.

4.3. El reto regulatorio y la irrupción de la explicabilidad (XAI)

A pesar de la superioridad predictiva del *machine learning*, su adopción masiva se vio frenada por su naturaleza de "caja negra", incompatible con normativas europeas y acuerdos internacionales como Basilea III. Para resolver esta brecha empírica, los ensayos modernos se han centrado en la Inteligencia Artificial Explicable (XAI).

Un punto de inflexión fue el trabajo del Banco de Inglaterra (Bracke et al., 2019), que evidenció la viabilidad de utilizar técnicas XAI para auditar algoritmos de riesgo. Actualmente, el estándar absoluto en la literatura es la metodología SHAP, desarrollada por Lundberg y Lee (2017) a partir de la teoría de juegos. Investigaciones aplicadas concretamente a plataformas P2P, como las de Ariza-Garzón et al. (2020) y Mondal y Shah (2023), han validado empíricamente que la aplicación de SHAP sobre modelos de Gradient Boosting permite desglosar la contribución exacta de cada variable financiera. Esto demuestra que es posible alcanzar la máxima precisión predictiva sin renunciar a la transparencia exigida por el regulador financiero.

Capítulo 5. Base de datos del trabajo

5.1. Descripción del *dataset* de Bondora

La ejecución de la parte empírica de este Trabajo Fin de Máster y el contraste de las hipótesis planteadas requieren de información veraz y detallada del mercado crediticio. Ante la habitual opacidad y las restricciones de confidencialidad del sector bancario tradicional, se ha optado por recurrir al ámbito de la financiación alternativa mediante el uso de datos procedentes de la industria *Fintech*. En concreto, el conjunto de datos seleccionado proviene de Bondora, una de las plataformas líderes en el sector de los préstamos *Peer-to-Peer* (P2P) en Europa. Este historial corporativo, respaldado por la política de transparencia de la entidad desde el año 2008, fue extraído y consolidado formalmente por Siddhartha (2021), lo que permite acceder a un registro histórico exhaustivo de las operaciones gestionadas en dicha plataforma.

La elección de esta base de datos es estratégica, ya que Bondora publica periódicamente historiales que incluyen tanto los créditos liquidados con éxito como aquellos que incurrieron en morosidad o impago definitivo (*default*). Esta dualidad convierte al *dataset* en el escenario analítico idóneo para el entrenamiento de algoritmos de *machine learning* orientados a tareas de clasificación binaria. En su estado original, la base de datos presenta una gran complejidad técnica, con cientos de miles de registros y más de un centenar de variables predictoras que recogen información multidisciplinar del cliente.

Dicha información se estructura esencialmente en tres grandes dimensiones analíticas que permiten un perfilado integral del riesgo. Por un lado, se encuentran los datos sociodemográficos, que abarcan el perfil personal del prestatario mediante variables como la edad, el nivel educativo, su situación laboral o el estado civil. Por otro lado, los datos financieros del préstamo definen las condiciones técnicas de la operación, tales como el importe solicitado, la tasa de interés, la duración del contrato y la carga de la cuota mensual esperada. Finalmente, los datos de riesgo y comportamiento proporcionan el historial crítico de impagos previos, los pasivos vigentes y el nivel de ingresos netos declarados.

Con el objetivo de maximizar la relevancia del estudio y evitar el fenómeno de *Concept Drift* (derivado de aplicar patrones de comportamiento de países bálticos o nórdicos a la realidad española), se ha llevado a cabo una primera fase metodológica que ha consistido en filtrar y aislar exclusivamente la cartera de clientes residentes en España. Sobre esta muestra acotada se han ejecutado posteriormente procesos de limpieza profunda, tratamiento de valores nulos e ingeniería de variables, sentando así las bases necesarias para el modelado algorítmico que se detalla en los apartados posteriores de este documento.

5.2. Filtrado, limpieza y definición de la variable objetivo

El primer paso metodológico sobre el conjunto de datos en bruto consistió en acotar la muestra a nuestro escenario de estudio. Partiendo de un archivo original de 179.000 registros, se aplicó un filtro geográfico y temporal para retener exclusivamente las operaciones de crédito correspondientes a clientes residentes en España entre los años 2013 y 2020, reduciendo la muestra inicial a 26.270 filas.

A continuación, se tomó una decisión crítica para la correcta definición de la variable objetivo (*Target*). Se procedió a eliminar todos los préstamos que se encontraban en estado activo (*Current*). El análisis exploratorio reveló que el 92% de estos créditos vivos pertenecían a los años 2019-2020 y tenían una maduración de apenas uno o dos años, frente a los cinco años de vida esperada. Mantener estos registros habría introducido un grave "ruido" estadístico en forma de falsos negativos (clientes que hoy pagan pero que podrían impagar mañana). Por tanto, el estudio se restringió únicamente a operaciones cerradas (Pagadas vs. Impagadas).

Posteriormente, se realizó un análisis de calidad de los datos para el tratamiento de valores nulos. Se estableció una regla de negocio estricta: la eliminación sistemática de toda columna con más de un 50% de datos ausentes. Esta purga permitió descartar métricas locales de otros países irrelevantes para España (ej. *CreditScoreEsEquifaxRisk*), versiones obsoletas del algoritmo de la plataforma (ej. *Rating_V0*) y datos censurados por privacidad (ej. *DateOfBirth*).

Tras este primer proceso de filtrado y calidad, el *dataset* de operaciones cerradas quedó consolidado en 24.352 registros y 42 variables predictoras iniciales. No obstante, tras aplicar las posteriores fases de erradicación de fuga de datos, purga de endogeneidad y creación de nuevos ratios financieros, el espacio de características definitivo con el que se entrenó el modelo óptimo quedó acotado a 35 variables predictoras altamente robustas.

5.3. Análisis Exploratorio de Datos (EDA)

Previamente a la fase de partición y modelado algorítmico, resulta imperativo realizar un Análisis Exploratorio de Datos (EDA) sobre el conjunto histórico consolidado. Esta auditoría visual y estadística permite comprender la estructura subyacente de la información, detectar posibles sesgos muestrales y fundamentar metodológicamente las decisiones de configuración de los modelos predictivos.


En primer lugar, el análisis de la variable objetivo (*Target*) revela un desbalanceo estructural en la cartera histórica de operaciones cerradas. La distribución de clases muestra que un 70,4% de las operaciones resultaron en impago definitivo, frente a un 29,6% de préstamos devueltos con éxito. Desde la perspectiva de la Ciencia de Datos, esta asimetría es crítica: entrenar un algoritmo estándar sobre una muestra desbalanceada provocaría que el modelo priorizara la precisión global a costa de ignorar la clase minoritaria (Brown & Mues, 2012). Por tanto, este hallazgo justifica empíricamente la necesidad de implementar técnicas de compensación matemática durante la fase de entrenamiento, configurando el

clasificador CatBoost con pesos balanceados (`auto_class_weights='Balanced'`) para ponderar inversamente las frecuencias de las clases en la función de pérdida. Esta técnica nativa evita que el modelo asuma falsamente que todas las operaciones resultarán en default, forzándolo a aprender los patrones de los clientes solventes (la verdadera clase minoritaria) a pesar de la alta siniestralidad natural de la cartera. Esta técnica de compensación nativa de CatBoost se priorizó frente a metodologías de sobremuestreo sintético (como SMOTE), ya que permite gestionar el desequilibrio estructural sin introducir ruido artificial ni distorsionar la distribución matemática real de las variables financieras.

Figura 1

Distribución de la Variable Objetivo en la Cartera de Préstamos de Bondora

Distribución de la Cartera Histórica (Variable Objetivo)




En segundo lugar, la inspección de las variables numéricas clave, como el capital solicitado (*AppliedAmount*) y los ingresos netos declarados (*IncomeTotal*), evidencia una marcada asimetría positiva (*Right-skewed distribution*), característica de los conjuntos de datos financieros. La mayor densidad de solicitantes se concentra en los tramos inferiores de renta y capital, presentando una larga cola hacia la derecha provocada por un reducido número de perfiles con ingresos o demandas de crédito excepcionalmente altas. Esta distribución no normal subraya la limitación teórica de la Regresión Logística (estrictamente dependiente de supuestos paramétricos y normalidad) frente a la robustez de los algoritmos de árboles de decisión, que son insensibles a la escala y a los valores atípicos (*outliers*) unidimensionales.

Finalmente, el despliegue de la matriz de correlación lineal (evaluada mediante el

coeficiente de Pearson) permite auditar la interacción entre las características financieras del prestatario. El mapa de calor resultante expone la existencia de multicolinealidad entre diversas variables de capacidad de pago y endeudamiento. En el marco de los modelos estadísticos clásicos estipulados por la normativa internacional, esta colinealidad inflaría la varianza de los estimadores, exigiendo una purga masiva de columnas predictoras o la aplicación de técnicas de reducción de dimensionalidad matemática. Sin embargo, la elección de la arquitectura Gradient Boosting permite sortear esta barrera metodológica, dado que los ensamblados de árboles gestionan de forma nativa la colinealidad seleccionando el predictor de mayor ganancia de información en cada ramificación, sin comprometer la estabilidad estadística del sistema predictivo.

Figura 2

Matriz de Correlación Lineal de Pearson para el Análisis Exploratorio de Datos



Nota. Los tonos rojos indican una correlación lineal positiva entre las variables, mientras que los tonos azules representan una correlación negativa.

5.4. Ingeniería de Variables (Ratios financieros)

Con el objetivo de maximizar la capacidad predictiva de los algoritmos y dotar al modelo de una lógica económica interpretable, se procedió a la creación de variables sintéticas (Feature Engineering). En el ámbito del Scoring de crédito, la relación matemática entre atributos financieros suele ser más predictiva que los valores absolutos (Siddiqi, 2012).

Por ello, utilizando las variables numéricas puras del *dataset*, se calcularon tres ratios fundamentales del análisis de riesgo crediticio:

- *Payment-to-Income* (PTI): Mide la carga de la nueva cuota sobre los ingresos totales del cliente.

$$PTI = \frac{MonthlyPayment}{IncomeTotal}$$

- *Debt-to-Income* (DTI): Evalúa el nivel de apalancamiento previo del prestatario, relacionando las deudas que ya poseía con su capacidad de generar rentas.

$$DTI = \frac{LiabilitiesTotal}{IncomeTotal}$$

- *Liquidity-Margin*: Dimensiona la holgura financiera mensual en términos relativos, calculando qué porcentaje de su sueldo queda libre tras asumir las obligaciones.

$$Margin = \frac{FreeCash}{IncomeTotal}$$

5.5. Auditoría de fuga de datos (*Data Leakage*) y variables endógenas

El proceso final de preparación de la base de datos representó, posiblemente, el hito más crítico desde una perspectiva metodológica: la identificación y erradicación sistemática de la fuga de información (*Data Leakage*) y de cualquier forma de contaminación algorítmica. La validez legal y funcional de un modelo de originación de crédito en un entorno productivo real depende estrictamente de que sus predicciones se fundamenten, de forma exclusiva, en la información sociodemográfica y financiera de la que la entidad dispone en el momento preciso de la solicitud. Por esta razón, tras auditar el conjunto de datos y analizar las primeras iteraciones del entrenamiento, se determinó la necesidad de realizar dos fases de purga consecutivas destinadas a asegurar la viabilidad empírica del algoritmo y prevenir un sobreajuste (*overfitting*) irreal de los resultados.

La primera de estas etapas se centró en la erradicación de la fuga de datos temporales mediante la identificación y eliminación de múltiples variables que incorporaban información generada con posterioridad a la concesión del crédito. En concreto, se descartaron métricas que reflejan el comportamiento futuro del préstamo, tales como la reestructuración del crédito (*Restructured*), los costes de servicio del capital (*PrincipalDebtServicingCost*), el saldo acumulado de penalizaciones

(InterestAndPenaltyDebtServicingCost) y los intereses planeados hasta la fecha (PlannedInterestTillDate). La inclusión de estos atributos en el espacio de características habría permitido a la Inteligencia Artificial una lectura anacrónica de los eventos, invalidando por completo su capacidad predictiva ante la llegada de nuevos solicitantes de los que no se posee historial posterior.

Posteriormente, se procedió a la eliminación de la endogeneidad con el fin de consolidar un "Modelo Puro" y un motor de decisión totalmente independiente y libre de sesgos corporativos. Esta fase implicó la supresión de atributos asignados internamente por la propia plataforma de Bondora, cuya retención habría inducido un razonamiento circular en el modelo. Específicamente, variables como el *Rating* interno y el tipo de interés (Interest) habrían provocado que el algoritmo se limitara a replicar la política de precios preexistente de la empresa en lugar de evaluar el riesgo crediticio subyacente de forma autónoma. Complementariamente, se eliminaron las métricas vinculadas a la operativa del mercado secundario (BidsApi, BidsManual, BidsPortfolioManager) y el capital finalmente otorgado (Amount), garantizando así una separación estricta entre el perfil del solicitante y las decisiones operativas de la entidad. Finalmente, la predicción probabilística original de la plataforma (ProbabilityOfDefault) fue aislada por completo de cualquier fase de entrenamiento, preservándola bajo un estricto aislamiento exclusivamente para su uso en la validación comparativa final o *Benchmarking*.

5.6. Diccionario de Datos Final

Dado el alto número de características resultantes en el *dataset* final (35 variables), resultaría ineficiente detallarlas en su totalidad. A continuación, se expone un diccionario con una selección representativa de las variables financieras y sociodemográficas más relevantes que componen el núcleo analítico del modelo, seleccionadas por su peso tradicional en la teoría de evaluación del riesgo de crédito y su tipo, numérico o categórico:

Tabla 1

Diccionario Analítico de las Variables Predictoras Fundamentales del Modelo

Nombre de la Variable	Tipo	Descripción y Lógica de Negocio
LiabilitiesTotal	Numérico	Deudas previas del cliente. Cuantifica el historial de crédito o "huella bancaria" del prestatario, fundamental para distinguir a clientes conocidos frente a perfiles sin historial (<i>Thin File</i>).
PreviousRepaymentsBeforeLoan	Numérico	Comportamiento de pago histórico. Suma del capital devuelto con éxito en operaciones anteriores en la plataforma, actuando como indicador empírico de la voluntad de pago.
MonthlyPayment	Numérico	Cuota mensual esperada. Define la carga financiera directa de la nueva operación solicitada.


IncomeTotal	Numérico	Ingresos netos declarados. Principal métrica de solvencia que define la capacidad real del cliente para la absorción de nuevas deudas y generación de rentas.
LoanDuration	Numérico	Plazo de amortización. Estructura temporal del crédito expresada en meses. Mide el horizonte de exposición al riesgo de la operación.
Age	Numérico	Edad del prestatario. Factor sociodemográfico clásico utilizado para la segmentación de la madurez financiera del solicitante.
CreditScoreEsMicroL	Categórico	Calificación de riesgo externa específica para el mercado de microcréditos, clave para capturar el perfil de riesgo crediticio.
Education	Categórico	Nivel educativo máximo alcanzado por el solicitante (primaria, secundaria, superior, postgrado), utilizado como predictor conductual de estabilidad socio-financiera.
HomeOwnershipType	Categórico	Régimen de tenencia de la vivienda (propiedad, alquiler, hipoteca, vivienda familiar), indicador clásico de arraigo y estabilidad residencial.
EmploymentStatus	Categórico	Situación laboral del solicitante (cuenta ajena, autónomo, jubilado, desempleado), fundamental para proyectar la recurrencia y predictibilidad de los flujos de caja.
NewCreditCustomer	Categórico (Binario)	Indicador de si el usuario es un cliente nuevo en la plataforma, variable crítica para controlar la asimetría de información en la primera originación.

Capítulo 6. Metodología empleada

Una vez finalizada la etapa de preparación y limpieza de la base de datos, el siguiente paso empírico consistió en definir la estrategia de modelado predictivo. Para garantizar que los algoritmos fueran evaluados de forma rigurosa y evitar el sobreajuste (*overfitting*), se realizó una partición del conjunto de datos consolidado en tres subconjuntos independientes: un conjunto de entrenamiento (*Train set*, 80% de la muestra, equivalente a 19.481 operaciones), un conjunto de validación interna (*Validation set*, 10%, 2.435 operaciones) y un conjunto de prueba final completamente ciego (*Test set*, 10%, 2.436 operaciones). Sobre esta estructura, se diseñó un entorno de experimentación basado en la comparación de tres enfoques distintos.

Figura 3

Diagrama de Flujo de la Metodología y Arquitectura del Modelo Analítico



6.1. Definición del *Benchmark* (El modelo original de Bondora)

Para que el impacto de este Trabajo Fin de Máster tuviera validez de negocio, fue imperativo comparar los nuevos desarrollos frente al estándar actual de la industria. Por ello, se estableció como *baseline* competitivo la predicción nativa de la plataforma, denominada ProbabilityOfDefault. Esta variable, que fue aislada durante la fase de limpieza para evitar la fuga de datos, fue evaluada sobre el conjunto de *Test*. La hipótesis metodológica planteó que este algoritmo sufriría de *Concept Drift* (sesgo poblacional) al haber sido entrenado originalmente con perfiles de países nórdicos y bálticos, resultando ineficiente para ordenar el riesgo en la coyuntura sociodemográfica española.

6.2. Modelo Tradicional (Regresión Logística)

Para establecer un segundo punto de comparación algorítmico que cumpliera con los estándares regulatorios clásicos de la banca tradicional (Acuerdos de Basilea), se procedió a la configuración de una Regresión Logística.

Dada la naturaleza paramétrica de este modelo, que es altamente sensible a la magnitud de los predictores y restrictivo ante variables alfanuméricas, se diseñó un *Pipeline* de preprocesamiento matemático específico. Las variables categóricas fueron transformadas mediante codificación binaria (*One-Hot Encoding*), eliminando así posibles relaciones ordinales espurias. Paralelamente, las variables numéricas continuas se estandarizaron (*StandardScaler*), sustrayendo la media y escalando a varianza unitaria. Esta transformación fue vital para garantizar que coeficientes de diferente magnitud (por ejemplo, el volumen total de ingresos frente a un ratio porcentual pequeño como el PTI) penalizaran de forma equitativa en la función de coste del modelo.

6.3. Modelo Avanzado (CatBoost)

El núcleo predictivo del trabajo se fundamentó en la arquitectura Gradient Boosting, seleccionando específicamente el algoritmo CatBoost (*Categorical Boosting*) desarrollado por Prokhorenkova et al. (2018). Su elección se justificó por su eficiencia empírica superior en el manejo de variables categóricas sin necesidad de aplicar el preprocesamiento exhaustivo que requiere la econometría clásica.

Previo al entrenamiento, se aplicó una conversión de tipos (*type casting*) a toda la matriz de características categóricas, imputando los nulos remanentes con la categoría explícita "Desconocido" para que el algoritmo lo procesara como un patrón predictivo más.

Por último, para maximizar el rendimiento predictivo del clasificador, se aplicó una técnica de búsqueda aleatoria de hiperparámetros (Randomized Search) evaluada mediante validación cruzada de 3 pliegues (CV=3). Para garantizar la reproducibilidad exacta del experimento por terceros, se fijó la semilla aleatoria (*random_state*) en el valor 42 en todas las particiones y algoritmos. El espacio de búsqueda evaluó distintas tasas de aprendizaje (0.01, 0.05, 0.1), profundidades de árbol (4, 6, 8) y volumen de estimadores (500, 1000). Los resultados determinaron que la configuración matemática óptima del ensamblado se alcanzaba limitando el crecimiento a 500 iteraciones, con una profundidad estructural de 8

y una tasa de aprendizaje de 0.05.

Adicionalmente, para prevenir el sobreajuste (*overfitting*) durante la fase de entrenamiento, se implementó una técnica de detención temprana (*early stopping*) con una paciencia operativa de 50 iteraciones.

6.4. Metodología de Interpretabilidad (XAI - SHAP)

La principal limitación de los modelos de Gradient Boosting en entornos regulatorios es su naturaleza de "caja negra". Para solventar esta opacidad, se aplicó el marco analítico SHAP (*SHapley Additive exPlanations*), consolidado por Lundberg y Lee (2017). Mediante la extracción de la importancia de variables (*Feature Importance*), se generaron visualizaciones que revelaron no solo el peso relativo de cada variable, sino la dirección de su impacto en la probabilidad de impago. Esto permitió auditar si el algoritmo había interiorizado de forma autónoma una lógica financiera coherente (basada en capacidad de pago e historial) o si, por el contrario, se apoyaba en correlaciones espurias.

6.5. Diseño del *Stress Testing* Macroeconómico

Finalmente, y con el objetivo de dotar al proyecto de una perspectiva integral de gestión de riesgos, la metodología concluyó con el diseño de una prueba de esfuerzo (*Stress Testing*). Se simularon escenarios macroeconómicos adversos sobre la cartera de clientes del conjunto de prueba mediante un *shock* multifactorial severo. Concretamente, se programó una contracción del 20% en los ingresos netos declarados por los clientes (*Income Total*), un incremento del 15% en el volumen de sus deudas previas (*Liabilities Total*) simulando un repunte inflacionario, y un endurecimiento del 10% en la cuota mensual del préstamo solicitado (*Monthly Payment*). Tras recalcular los márgenes de liquidez de cada perfil, el objetivo fue someter al modelo CatBoost a estas nuevas condiciones de estrés para evaluar su resiliencia y observar empíricamente cómo migraban las clasificaciones de riesgo ante una crisis económica sistémica.

6.6. Evaluación del Rendimiento Algorítmico y Optimización Teórica

Para cuantificar la capacidad predictiva de los modelos desarrollados, se estableció un marco de evaluación robusto fundamentado en el análisis de la curva ROC-AUC (*Area Under the Receiver Operating Characteristic Curve*). Esta métrica resultó idónea por su invarianza ante el desbalanceo de clases, permitiendo medir la capacidad pura del algoritmo para discriminar entre perfiles solventes y fallidos (Fawcett, 2006).

Adicionalmente, se integró un simulador de impacto económico para traducir las métricas estadísticas abstractas a rentabilidad financiera real. Para ello, se calculó un Umbral Óptimo de Decisión (*Optimal Threshold*) enfocado en la maximización operativa.

Para ello, se calculó un Umbral Óptimo de Decisión enfocado en la maximización operativa (fijado en el 26%). No obstante, con el fin de auditar los límites de seguridad del modelo, se simuló también un escenario teórico de máxima aversión al riesgo mediante un umbral defensivo del 9%; es bajo esta configuración extrema donde la Inteligencia Artificial

lograría bloquear el 100% del capital tóxico. Al contraponer ambos enfoques, se determina que la configuración operativa real al 26% es la óptima para el negocio, ya que logra evitar el 99.1% del capital moroso real de la cartera, manteniendo un equilibrio perfecto entre la protección del balance y la viabilidad comercial del activo financiero.

6.7. La Paradoja de la Selección Adversa en Mercados Subprime

La optimización de un umbral estrictamente conservador genera una paradoja de selección adversa en estos mercados alternativos, donde el rechazo sistemático destruiría la viabilidad comercial de la plataforma. Para solventar esta limitación, la metodología de este proyecto descarta la denegación binaria genérica en favor de una estrategia de estratificación continua. De este modo, las predicciones probabilísticas alimentarán un Sistema de Clasificación Interna (*Rating*) que permitirá aplicar estrategias dinámicas de fijación de precios (*Risk-Based Pricing*), cuyo impacto económico se detallará empíricamente en el siguiente capítulo.

Capítulo 7. Resultados y discusión

7.1. Evaluación del Rendimiento Predictivo

7.1.1. Capacidad de Discriminación General (ROC-AUC)

La primera fase de evaluación de resultados consiste en medir la capacidad de discriminación pura de los algoritmos desarrollados frente al estándar actual del mercado. Para ello, se ha utilizado la métrica ROC-AUC, evaluada íntegramente sobre el conjunto de prueba ciego (Test set) para garantizar la robustez de las conclusiones y evitar el sobreajuste.

Tal y como se hipotetizó en los capítulos preliminares, el modelo nativo de la plataforma (ProbabilityOfDefault) demostró un rendimiento deficiente al ser aplicado a la cohorte de prestatarios españoles, obteniendo un AUC de 0.4928. Este resultado no solo es estadísticamente equivalente al azar, sino que presenta una ligera inversión predictiva (al situarse por debajo de 0.50). Esto implica un fallo estructural grave: el algoritmo nórdico asigna Este resultado evidencia un deterioro significativo del rendimiento del modelo original al ser aplicado sobre la cohorte española analizada. Si bien una posible explicación reside en el fenómeno de *Concept Drift* derivado de diferencias sociodemográficas y financieras entre mercados, este comportamiento también podría estar influenciado por divergencias en los procesos históricos de originación, criterios internos de concesión de crédito, distribución de variables y dinámicas regulatorias entre países. En consecuencia, los resultados deben interpretarse como una señal de limitada capacidad de generalización del modelo original fuera del entorno poblacional para el que fue diseñado.

Por su parte, el modelo estadístico tradicional (Regresión Logística), configurado para cumplir con los requisitos de interpretabilidad lineal de los Acuerdos de Basilea, logró corregir este sesgo alcanzando un AUC de 0.6522. Este incremento demuestra que la limpieza de datos y la ingeniería de variables financieras (PTI, DTI, Margen de Liquidez) aportaron un valor analítico significativo.


Sin embargo, el rendimiento predictivo óptimo se alcanzó mediante el uso de la arquitectura avanzada Gradient Boosting. El algoritmo CatBoost, operando de manera algorítmicamente independiente y tras haber sido sometido a una estricta purga de variables endógenas y fuga de información (*Data Leakage*), alcanzó un AUC definitivo de 0.7071. Este resultado muestra una mejora consistente respecto al *benchmark* y un rendimiento competitivo para un entorno *subprime* que sugiere el potencial de aplicación operativa del modelo para su hipotético despliegue comercial.

Adicionalmente, cabe destacar que este rendimiento se obtuvo tras aplicar una optimización automatizada de hiperparámetros (Randomized Search), configurando la profundidad de los árboles en 8 niveles y aplicando pesos balanceados para compensar el desequilibrio estructural del mercado subprime, asegurando que el algoritmo caracterice correctamente a la clase minoritaria (clientes solventes) sin perder su capacidad de detección sobre la clase mayoritaria (impagos). El éxito de esta compensación algorítmica queda matemáticamente demostrado al complementar el análisis con la curva Precision-Recall (PR), donde el modelo alcanza un PR-AUC de 0.8376. A diferencia del ROC generalista, esta métrica es estrictamente exigente en escenarios desbalanceados (70,4%

de morosidad), lo que confirma de forma rotunda que el algoritmo es capaz de cazar el riesgo sin disparar los falsos positivos.

Figura 4

Curva ROC y Comparación del Rendimiento Predictivo entre CatBoost y el Modelo Benchmark



7.1.2. Métricas regulatorias de Riesgo de Crédito: Coeficiente de Gini y Estadístico KS

Con el objetivo de alinear la validación del modelo CatBoost con los exigentes estándares de la industria financiera y las directrices de supervisión de riesgos (marcos de Basilea), la evaluación trasciende el análisis generalista de la curva ROC para incorporar las métricas soberanas en *Credit Scoring*: el Coeficiente de Gini y el estadístico de Kolmogorov-Smirnov (KS) (Baesens et al., 2016).


El Coeficiente de Gini, derivado matemáticamente del área bajo la curva: $Gini = 2$

* $AUC - 1$, se sitúa en un valor de 0.4142 (41.42%). En la literatura especializada en carteras de financiación alternativa (unsecured P2P lending) y segmentos subprime, superar el umbral crítico del 40% denota una robustez predictiva muy competitiva. Este resultado certifica que, a pesar del alto grado de entropía y volatilidad inherente a la base de datos de Bondora, el algoritmo preserva una notable capacidad para separar el riesgo subyacente de los perfiles analizados.

De forma complementaria, la idoneidad del modelo se constata mediante la segregación de distribuciones a través del análisis de las funciones acumuladas. El estadístico KS, que mide la máxima distancia vertical entre las curvas de distribución acumulada de los clientes solventes y los que incurren en impago, alcanza un valor empírico de 0.2900 (29.00%). En el ámbito de la gestión del riesgo de crédito, un resultado de 0.2900 se clasifica formalmente como un poder discriminante aceptable y técnicamente consistente, al situarse con precisión en el rango de tolerancia (0.20–0.30) estipulado por la teoría clásica (Baesens et al., 2016). Esto confirma que los ensamblados de árboles de decisión optimizan la separación de ambas poblaciones en los deciles de mayor exposición. En términos operativos, esta métrica garantiza que la arquitectura algorítmica no sufre de una descalibración severa en las colas de la distribución, proporcionando un marco cuantitativo fiable para la posterior implementación de las políticas de exclusión y las estrategias de *risk-based pricing*.

Figura 5

Curva de Kolmogorov-Smirnov para la Evaluación del Poder Discriminante del Algoritmo



7.1.3. Validación de la Calibración de Probabilidades


En la analítica de riesgo de crédito, la capacidad de discriminación del modelo debe complementarse con una estricta validación de la exactitud de sus predicciones. Es imperativo que la Probabilidad de Impago (PD) estimada por el algoritmo CatBoost refleje con fidelidad la tasa empírica de morosidad observada, garantizando así la solidez del cálculo de pérdida esperada y la correcta asignación de precios basada en el riesgo (*Risk-Based Pricing*).

Para verificar este ajuste, se analiza el diagrama de calibración, que contrasta las probabilidades predichas por el sistema frente a la frecuencia real de los impagos

observados en el conjunto de evaluación.

Figura 6

Curva de Calibración y Fiabilidad en la Proyección de Probabilidades de Impago



Al observar el diagrama, se constata que la curva del modelo sigue fielmente la tendencia creciente de la diagonal de referencia, lo que garantiza la preservación de la monotonidad del riesgo: a mayor probabilidad predicha por CatBoost, mayor es la tasa de impago observada empíricamente. No obstante, como es intrínseco a las arquitecturas basadas en Gradient Boosting, se aprecia una leve desviación de carácter sigmoideo en los deciles extremos. Esta forma geométrica indica que el algoritmo tiende a ser conservador, evitando emitir probabilidades absolutas del 0% o del 100% en las colas de la distribución. A pesar de esta natural infra-confianza en los extremos, el fuerte alineamiento en los tramos centrales de decisión valida que las estimaciones guardan una proporcionalidad directa y fiable con la siniestralidad real.

Para complementar el análisis visual de la calibración, resulta imperativo evaluar la exactitud absoluta de las predicciones. Mientras que métricas como la curva ROC o el estadístico KS miden la capacidad del modelo para ordenar a los clientes según su nivel de riesgo, el Brier Score se emplea para cuantificar la precisión real de esas probabilidades, midiendo el error cuadrático medio entre la probabilidad estimada y el resultado empírico (Baesens et al., 2016). En la evaluación de este modelo, el Brier Score se sitúa en 0.2135; un valor bajo que certifica un reducido margen de error global. Esta consistencia estadística valida que las puntuaciones emitidas constituyen una base operativa sólida para la posterior estratificación corporativa de la cartera y la optimización del modelo de negocio.

7.2. Transparencia Algorítmica e Interpretabilidad Global (SHAP *Summary Plot*)

La principal limitación normativa de los modelos de Gradient Boosting en el sector bancario es su naturaleza de "caja negra". Para solventar esta opacidad y cumplir con los requisitos de los reguladores europeos, se ha integrado el marco analítico SHAP (*SHapley Additive exPlanations*). Esta metodología basada en la teoría de juegos permite auditar el modelo en dos niveles: una visión macroeconómica de la cartera y una visión microeconómica a nivel de expediente individual.


7.2.1. Interpretabilidad Global: Motor de Decisión (SHAP *Summary Plot*)

Con el fin de comprender las políticas de riesgo que la Inteligencia Artificial ha interiorizado de forma autónoma, se ha generado un gráfico resumen de SHAP que permite auditar el modelo en un nivel macroeconómico. Esta visualización es fundamental, ya que ordena los predictores según su importancia global.

Cada punto representa a un prestatario histórico y su posición en el eje horizontal determina si una variable está empujando la predicción hacia el impago (derecha) o hacia la solvencia (izquierda). El color indica el valor empírico de la variable (tonos cálidos para valores altos, fríos para bajos).

Figura 7

Auditoría de Impacto Global y Dirección Predictiva de las Variables mediante Valores SHAP



Nota. Los colores cálidos (rojo) indican valores altos de la característica en el cliente, mientras que los colores fríos (azul) indican valores bajos.

La auditoría de la matriz SHAP permite extraer conclusiones de alto valor, revelando que el algoritmo ha interiorizado una jerarquía de solvencia donde el perfil socio-conductual del prestatario actúa como el vector de riesgo de mayor impacto global. Concretamente, la edad biológica (Age), la calificación crediticia externa (CreditScoreEsMicroL) y el nivel educativo (Education) se erigen como las tres características más discriminantes del sistema. Resulta especialmente revelador el patrón detectado en la variable educativa: el análisis visualiza cómo, una vez controladas otras variables financieras, el modelo asocia estadísticamente determinados niveles educativos con una mayor probabilidad de impago dentro de la muestra analizada, desvelando una complejidad multivariante indetectable mediante enfoques de *scoring* tradicionales. Asimismo, se observa que la cohorte de mayor edad tiende a desplazar su predicción hacia el impago, reflejando una penalización algorítmica sobre los extremos demográficos.

Por su parte, las variables puramente financieras y de exposición operan como moduladores críticos de la capacidad de pago. El comportamiento histórico en la plataforma

(PreviousRepaymentsBeforeLoan) actúa como el principal mitigador de riesgo, reduciendo drásticamente la probabilidad de *default* a medida que el cliente demuestra fiabilidad empírica. Por el contrario, un volumen elevado de deuda previa consolidada (LiabilitiesTotal) y las solicitudes de capital alto (AppliedAmount) empujan la probabilidad hacia la mora, confirmando la lógica matemática del estrés patrimonial. Finalmente, la generación de rentas altas (IncomeTotal) opera como un escudo protector de la liquidez. Esta convergencia entre el aprendizaje automático y la teoría financiera garantiza la viabilidad regulatoria del sistema, demostrando que el modelo no solo captura patrones sociodemográficos complejos, sino que ampara sus decisiones finales en la liquidez y el historial probado del solicitante.

7.2.2. Interpretabilidad Local: Auditoría Individual de Expedientes


Más allá de las reglas de originación que rigen la cartera global, la normativa financiera vigente exige que las entidades sean capaces de explicar el motivo exacto que justifica la denegación o aprobación de cualquier solicitud de crédito. Para dar cumplimiento a este requerimiento de transparencia y evitar la opacidad inherente a los algoritmos de caja negra, se ha aplicado la metodología SHAP a nivel local. Esta técnica permite aislar un expediente concreto y trazar de qué manera cada atributo específico del solicitante suma o resta riesgo frente a la expectativa base de la institución.

En este sentido, la auditoría revela que el algoritmo no emite un juicio partiendo de la neutralidad absoluta, sino que inicia su evaluación desde la expectativa media del modelo, situando dicho anclaje en un valor base de $E[f(X)] = 0,127$. Es fundamental precisar desde el rigor algorítmico que este *expected value* se expresa en el espacio de log-probabilidades (*log-odds o raw margin*) y no representa una probabilidad directa del 12,7%. Si se aplicara la función sigmoide de manera aislada sobre este punto de partida, correspondería a una probabilidad inicial de impago del 53.17%, reflejando la alta siniestralidad natural de la cartera *subprime* antes de ponderar los atributos específicos del prestatario.

$$Probabilidad = \frac{1}{1 + e^{-0.127}}$$

Figura 8

Análisis de Interpretabilidad Local y Atribución de Riesgo para un Expediente Individual



Nota. Las barras rojas empujan la predicción hacia un mayor riesgo de impago, mientras que las barras azules mitigan el riesgo hacia el valor base.

Como se puede observar en la representación visual del expediente auditado, el modelo inicia una interacción dinámica de fuerzas contrapuestas. Por un lado, las fortalezas financieras del prestatario logran mitigar el riesgo de la operación de manera contundente. En este caso particular, un abultado historial de pagos previos (942.35 €), la percepción de ingresos netos mensuales de 2,500 € y una estabilidad laboral superior a los cinco años se consolidan como los motores principales para recomendar la aprobación del crédito. Estas características generan un impacto negativo en la probabilidad de mora, empujando la predicción hacia la zona de solvencia y neutralizando las posibles debilidades del perfil.

A pesar de la solidez general, el expediente presenta ciertas tensiones que el algoritmo detecta y penaliza. Factores como la edad del solicitante (42 años) o el propio importe del capital demandado (530 €) actúan como fuerzas que intentan desplazar la predicción hacia el impago. Sin embargo, al contraponer ambas tendencias en el gráfico de fuerzas, la magnitud de estas penalizaciones resulta insuficiente frente a la capacidad de pago demostrada por las variables positivas.

Como resultado de este análisis detallado, la solvencia del cliente arrastra la predicción final desde el riesgo medio hasta una puntuación algorítmica de $f(x) = -0.822$. Para transformar esta cifra técnica en una métrica interpretable por los gestores de riesgos, se aplica la función logística o sigmoide, la cual se define matemáticamente como:

$$Probabilidad\ Impago = \frac{1}{1 + e^{-f(x)}} = \frac{1}{1 + e^{0.822}} \approx 0.3053$$

A través de esta transformación, se obtiene una probabilidad empírica de impago del 30,53%. Este desarrollo cuantitativo expone claramente la dinámica del modelo: las fortalezas financieras del solicitante lograron mitigar el riesgo de la operación, reduciendo la probabilidad desde el umbral base del entorno ($\approx 53.17\%$) hasta el valor definitivo. Si bien en el marco de la banca tradicional un nivel de riesgo superior al 30% podría justificar un rechazo preventivo, en el ecosistema de la financiación alternativa este perfil se considera plenamente operativo.

7.3. Optimización y Calibración del Umbral de Decisión (*Cut-off*)

La determinación del umbral de decisión (*cut-off*) constituye una fase crítica en el despliegue del modelo, ya que establece el límite de probabilidad de impago a partir del cual una solicitud de crédito es rechazada. Para garantizar una gestión de riesgos robusta, se ha realizado una calibración basada en dos escenarios diferenciados que permiten contrastar la seguridad del capital frente a la rentabilidad del negocio.

7.3.1. Escenario de Estrés: Mitigación de Pérdidas Capitales (Umbral 9%)

El primer análisis se ha orientado a la protección del balance bajo un enfoque de máxima aversión al riesgo. En esta configuración, se ha aplicado una Severidad de la Pérdida (LGD) del 100%, asumiendo una tasa de recuperación nula ante el incumplimiento del prestatario. Aunque en escenarios de recobro maduros podría existir una recuperación judicial marginal (situando la LGD real en un 60-80%), esta premisa responde a la naturaleza de los activos analizados: préstamos sin garantía real (*unsecured loans*). En este segmento, la ausencia de colaterales y los elevados costes procesales de recobro suelen neutralizar cualquier intento de recuperación de capital una vez se produce el *default*. Bajo estas condiciones de estrés, la optimización de la Matriz de Costes sitúa el umbral técnico en el 0.09 (9%). Este nivel identifica el punto de máxima protección defensiva, priorizando la integridad del capital expuesto por encima de la originación de nuevo volumen de negocio.

7.3.2. Escenario Operativo: Optimización por Margen de Rentabilidad (Umbral 26%)


Para la aplicación del modelo en un entorno de explotación real, el umbral debe alinearse con la estructura de ingresos de la plataforma. A tal efecto, se ha integrado en la función de coste el Margen de Beneficio Esperado obtenido del análisis histórico del *dataset*, que se sitúa en el 57.22% sobre el capital prestado.

Al incorporar este lucro cesante, el modelo evalúa el coste de oportunidad derivado de la exclusión de prestatarios solventes. Dado que el elevado margen de intereses de los créditos vigentes es capaz de absorber un cierto nivel de morosidad, el punto de eficiencia económica se desplaza hacia un perfil más dinámico. La calibración resultante establece un umbral operativo del 0.26 (26%), punto en el cual se maximiza el beneficio neto de la cartera al equilibrar la captura de ingresos con la pérdida esperada por impago.

En conclusión, mientras que el umbral del 9% define el límite de seguridad ante escenarios de crisis sistémica, el umbral del 26% representa la configuración óptima para la operativa recurrente en el mercado de financiación alternativa.

Figura 9

Curva de Optimización del Umbral de Decisión y Minimización del Coste Financiero



7.4. Simulación de Impacto Económico: Análisis de Clasificación

Tras la determinación de los umbrales óptimos, resulta fundamental cuantificar su impacto en la rentabilidad de la entidad. El éxito de un modelo de riesgo de crédito no reside únicamente en su capacidad predictiva (métrica estadística), sino en su capacidad para maximizar el valor neto de la cartera (métrica de negocio).


En este apartado, se evalúa cómo la transición del umbral de estrés al umbral operativo transforma la composición de la cartera aprobada y, en consecuencia, el balance final de beneficios.

7.4.1. Evaluación del Comportamiento en Escenarios de Riesgo

Para visualizar el rendimiento del modelo CatBoost, se procede a contrastar la capacidad de clasificación mediante el uso de matrices de confusión. Estas herramientas permiten identificar con precisión el volumen de clientes correctamente clasificados frente a los errores de tipo I (Falsos Positivos) y tipo II (Falsos Negativos).

Figura 10

Comparativa de Matrices de Confusión: Escenario de Estrés (9%) frente a Escenario Operativo (26%)



Como se observa en la comparativa gráfica, el desplazamiento del umbral del 9% al 26% genera una reconfiguración estratégica:

1. El Escenario de Estrés (9%) garantiza una exposición mínima al impago, actuando como un mecanismo de protección de capital. Sin embargo, su rigidez provoca un elevado lucro cesante al descartar clientes que habrían sido rentables.
2. El Escenario Operativo (26%) asume un incremento marginal del riesgo de *default*, pero a cambio logra una tasa de aprobación significativamente mayor entre los perfiles solventes, capturando el margen de interés necesario para la viabilidad comercial de la plataforma.

7.4.2. Cuantificación del Valor Económico Añadido

Para comprender el impacto real del modelo en las cuentas de la entidad, es necesario traducir los aciertos y errores estadísticos a euros. En el mercado de préstamos sin aval, los errores tienen un peso económico muy diferente:

- El coste de aceptar a un moroso: Supone la pérdida íntegra del capital prestado (100% de pérdida), ya que las posibilidades de recuperar el dinero en los juzgados son casi nulas.
- El coste de rechazar a un cliente solvente: Supone perder la oportunidad de cobrar los intereses de ese préstamo (57,22% de lucro cesante medio, según los datos históricos).

Al calibrar el modelo en el umbral operativo del 26%, el modelo internaliza esta estructura de costes durante la optimización: asume un ligero incremento en la morosidad porque sabe que el alto beneficio generado por los nuevos clientes solventes compensará con creces esas pérdidas.

Para demostrarlo, se ha simulado financieramente el comportamiento del modelo CatBoost sobre la cartera de evaluación, comparándolo con las pérdidas reales que sufrió Bondora. Los resultados son concluyentes:

3. Capital tóxico bloqueado (Dinero salvado): El algoritmo identificó y denegó créditos a morosos por valor de 3,311,175 €.
4. Lucro cesante (Dinero sano sacrificado): Al aplicar el filtro de seguridad, se rechazó por precaución a algunos clientes que finalmente resultaron solventes, reteniendo un capital de 1,039,964 € que dejó de generar intereses.

Al restar el dinero sacrificado del capital salvado, el Ahorro Neto Estimado para la entidad asciende a 2,271,211 €.

Esta cifra demuestra que el modelo no es solo una barrera de seguridad, sino una herramienta potencialmente útil para mejorar la rentabilidad ajustada al riesgo. Bajo este umbral óptimo, el algoritmo habría evitado perder el 99.1% del capital tóxico, justificando plenamente la adopción de técnicas de *machine learning* frente a los sistemas de puntuación tradicionales.

7.5. Sistema de Clasificación Interna (*Ratings*) y Estratificación del Riesgo

Tras la determinación del umbral operativo óptimo en el 26%, resulta imperativo desplegar un Sistema de Clasificación Interna (*Internal Rating System*) que permita gestionar la heterogeneidad de la cartera aprobada. El algoritmo no se limita a emitir una decisión dicotómica (concesión o rechazo), sino que calcula una Probabilidad de Impago (PD) continua que habilita la segmentación de los prestatarios.

Esta estratificación es la piedra angular del *Risk-Based Pricing* (fijación de precios basada en el riesgo), permitiendo a la entidad ajustar la tasa de interés exigida a cada cliente en función de su nivel específico de solvencia.

7.5.1. Arquitectura de Segmentación

Una vez validada la precisión del modelo y su capacidad para explicar las decisiones individuales, el último paso para transformar el algoritmo en una herramienta de negocio funcional es la creación de una arquitectura de segmentación. En el entorno de la financiación alternativa, la gestión del riesgo no se basa en una decisión binaria de 'aprobado' o 'denegado' de forma rígida, sino en la capacidad de clasificar a los solicitantes en diferentes estratos de riesgo. Esta estratificación, denominada sistema de Rating, permite a la entidad organizar su cartera según la probabilidad de impago estimada por la Inteligencia Artificial, asignando a cada grupo un perfil de riesgo específico que guiará la

política comercial posterior.

La lógica de esta segmentación reside en la necesidad de equilibrar la tasa de aprobación con la rentabilidad esperada. Mientras que la banca tradicional suele descartar perfiles con una probabilidad de impago moderada, el modelo desarrollado en este trabajo permite identificar matices dentro de esos segmentos. Al agrupar a los prestatarios en categorías que van desde la excelencia crediticia hasta el riesgo extremo, se establece un marco objetivo para aplicar una estrategia de *Risk-Based Pricing*. De este modo, la arquitectura de segmentación no solo sirve como una herramienta de control de riesgos, sino como el motor que define la competitividad de la entidad en el mercado.

7.5.2. Distribución Empírica de la Cartera

Al proyectar la arquitectura de segmentación sobre las predicciones probabilísticas del modelo CatBoost en el conjunto de evaluación, se obtiene la distribución volumétrica y su correspondiente validación empírica (*backtesting*).

Es fundamental señalar que, dado que el *dataset* original de Bondora se compone exclusivamente de préstamos que fueron efectivamente concedidos en la realidad, el modelo actúa en este punto como un auditor retroactivo. El cruce de la clasificación interna con los impagos reales observados arroja los siguientes resultados:

Tabla 2

Estructura de la Cartera de Validación y Distribución de Clientes por Tramo de Riesgo

Rating del cliente	Riesgo	Total clientes	Impagos reales	Tasa de mora real (%)	Estado
A	Bajo (0% - 5%)	14	1	7.14	Aprobado
B	Medio - Bajo (5% - 10%)	21	1	4.76	Aprobado
C	Medio (10% - 15%)	15	4	26.67	Aprobado
D	Alto (15% - 20%)	27	9	33.33	Aprobado
E	Límite operativo (20% - 26%)	53	17	32.08	Aprobado
Rechazo	> Umbral 26%	2,306	1,670	72.42	Rechazado

7.5.3. Aproximación al Precio Técnico (*Risk-Based Pricing*)

Para monetizar las predicciones del modelo y garantizar la rentabilidad operativa, a cada tramo de la arquitectura de segmentación previamente definida se le debe asignar un precio técnico (*Technical Price*) de referencia. Asumiendo un escenario conservador donde la Severidad de la Pérdida (LGD, *Loss Given Default*) es del 100% sobre el capital prestado, la prima de riesgo matemática necesaria para que la entidad alcance el punto de equilibrio en cada escalón se define mediante la siguiente expresión empírica:

$$\text{Prima_Riesgo_Mín} = \frac{PD_{media} * LGD}{1 - PD_{media}}$$

Aplicando esta formulación empírica sobre la Probabilidad de Impago (PD) media proyectada por el algoritmo para cada tramo, se configura una curva de precios monótona y coherente con el riesgo asumido:

Tabla 3

Aproximación al Precio Técnico y Estructura de Primas de Riesgo Mínimas por Niveles de Rating

Rating del cliente	Riesgo predicho	Prima de Riesgo Mínima Calculada (%)
A	Bajo (0% - 5%)	2.56
B	Medio - Bajo (5% - 10%)	8.11
C	Medio (10% - 15%)	14.29
D	Alto (15% - 20%)	21.21
E	Límite operativo (20% - 26%)	29.97
Rechazo	> Umbral 26%	

Al sumar a este resultado una tasa base constante (destinada a cubrir el coste estructural de fondeo y el margen de beneficio objetivo), se obtiene una Tasa Anual Equivalente (TAE) sugerida para cada letra. Como se observa en la Tabla 3, esta aplicación matemática del modelo permite a la entidad compensar el elevado riesgo del segmento *Subprime* (*Rating E*) exigiendo primas base en el entorno del 30%. De forma simultánea, habilita comercialmente a la institución para ofrecer tasas mucho más bajas y competitivas (inferiores al 3%) con el fin de captar volumen de forma agresiva en los segmentos de máxima solvencia (*Rating A*). Asimismo, esta proyección justifica financieramente el umbral de rechazo óptimo fijado en el 26%, ya que los perfiles que lo superan exigirían primas

mínimas fuera de mercado, resultando en un producto de crédito económicamente inviable.

7.5.4. Análisis de la Eficiencia en la Clasificación y Selección del Riesgo

El análisis de la tabla de calibración revela el impacto transformador del modelo sobre la política de riesgos histórica de la entidad. Se extraen tres conclusiones fundamentales de naturaleza económica y estadística:

1. Capacidad de Saneamiento de la Cartera: La cifra de 2,306 rechazos frente a solo 130 aprobaciones evidencia que el algoritmo identifica con precisión la toxicidad de concesión crediticia histórica de la plataforma. El modelo habría evitado la concesión de crédito a un colectivo cuya tasa de mora real fue del 72.42%. Este poder discriminante valida la implementación del sistema para transitar desde una política de concesión indiscriminada hacia una selección de alta rentabilidad.
2. Volatilidad por Tamaño Muestral: Se observa que en los tramos C, D y E, la tasa de mora real supera el rango de probabilidad predicho. Este fenómeno es una consecuencia matemática directa del rigor del modelo: al ser tan selectivo, el número de clientes aprobados en cada tramo es reducido (volúmenes de entre 14 y 53 registros). En estas condiciones de baja densidad muestral, la materialización de un número reducido de impagos incrementa drásticamente la proporción porcentual observada, una varianza estadística común en la validación de carteras de nicho.

A pesar de esta fuerte volatilidad matemática, la calibración estratégica del modelo garantiza su viabilidad financiera. El amplio margen de beneficio recuperado al establecer el umbral de exclusión en el 26% absorbe con solvencia estas desviaciones empíricas locales, protegiendo la cuenta de resultados global de la entidad.

3. Concentración Demográfica en el Segmento *High-Yield*: La mayor parte del volumen aprobado se concentra en el *Rating E* (40.7%). Lejos de indicar una preferencia o sesgo del algoritmo por los perfiles de alto riesgo, esta distribución refleja fielmente la demografía natural de la demanda en las plataformas de financiación alternativa. El algoritmo CatBoost clasifica de forma objetiva la probabilidad de impago, pero dado que la base de prestatarios que acude a este mercado presenta una calidad crediticia estructuralmente inferior a la de la banca tradicional, el volumen absoluto de clientes en la franja del 20% al 26% es lógicamente muy superior al de perfiles *Prime (Rating A)*. La optimización del umbral simplemente permite integrar y rentabilizar esta masa crítica mayoritaria que, aun estando en el límite superior de la tolerancia al riesgo, mantiene una esperanza matemática de retorno positiva.

7.6. Stress Testing Macroeconómico y Análisis de Sensibilidad

La validación de un modelo de riesgo de crédito no puede limitarse a su rendimiento en condiciones de estabilidad. Bajo las directrices de Basilea III y la normativa IFRS 9, es imperativo someter al algoritmo a escenarios adversos para evaluar su robustez y la sensibilidad de la cartera ante deterioros del ciclo económico.

7.6.1. Diseño del Escenario de Crisis Severa

Se ha diseñado un *shock* multifactorial que simula una "tormenta perfecta" sobre el

conjunto de evaluación, afectando directamente a los pilares de la capacidad de pago de los prestatarios:

- *Shock* de Ingresos (-20%): Simulación de un escenario de recesión con desempleo parcial o pérdida de poder adquisitivo (IncomeTotal).
- *Shock* de Carga Financiera (+15%): Incremento del endeudamiento previo (LiabilitiesTotal) por efectos de inflación y encarecimiento de pasivos vinculados a tipos variables.
- *Shock* de Tipos de Interés (+10%): Aumento de la cuota mensual del préstamo solicitado (MonthlyPayment), reflejando un endurecimiento de las condiciones de financiación.


Tras la inyección de estos impactos, se han recalculado las ratios de solvencia para que el modelo CatBoost procese la nueva realidad financiera de los sujetos.

7.6.2. Análisis de la Migración de Cartera y Cortafuegos de Riesgo

Al proyectar el escenario de crisis, se observa una transformación radical en la distribución del riesgo, como se detalla en la siguiente comparativa:

Figura 11

Impacto del Escenario Macroeconómico Adverso sobre la Distribución del Riesgo de la Cartera



El resultado visual presenta una asimetría extrema que constituye la prueba de mayor valor sobre la seguridad del modelo. Mientras que en un escenario normal el

algoritmo ya es selectivo, ante una crisis macroeconómica el sistema activa un bloqueo preventivo masivo.

Como se observa en la Figura 11, la columna de "Rechazado (>26%)" se convierte en el destino mayoritario de la cartera. Este fenómeno no representa un error de escala, sino la capacidad del modelo para detectar que, ante un entorno hostil, la inmensa mayoría de los perfiles que eran marginalmente aceptables (Ratings D y E) cruzan instantáneamente la frontera de impago técnico.

La práctica desaparición de los *Ratings* de alta calidad y el crecimiento exponencial del segmento de rechazo validan la utilidad del modelo como un cortafuegos dinámico: el sistema prefiere sacrificar el volumen de negocio antes que comprometer la solvencia de la entidad, demostrando una sensibilidad elástica que garantiza la supervivencia del capital incluso en escenarios de recesión profunda.

Esta migración masiva hacia el segmento de rechazo tiene una lectura financiera crítica que trasciende la mera estadística. Si la plataforma mantuviera una política de concesión estática (ignorando el deterioro de los márgenes de liquidez de los clientes por la crisis), la inyección de los *shocks* macroeconómicos dispararía la morosidad real muy por encima de los umbrales de rentabilidad, provocando un colapso en el balance general.

Al contar con un sistema algorítmico dinámico, el incremento generalizado en la Probabilidad de Impago (PD) de los expedientes hace que estos crucen mecánicamente la frontera del 26%. En términos económicos, la simulación de este "cortafuegos" significa que el modelo detiene de forma autónoma la creación de nuevo crédito tóxico. Aunque esto reduce drásticamente el volumen de negocio y el ingreso por intereses a corto plazo, evita que la entidad asuma millones de euros en pérdidas irrecuperables (LGD del 100%). Por tanto, se concluye que el umbral del 26% no solo optimiza la rentabilidad en periodos de expansión, sino que demuestra una elasticidad financiera perfecta para blindar el capital de los inversores ante ciclos recesivos severos, garantizando la supervivencia a largo plazo de la plataforma P2P.

Capítulo 8. Conclusiones

El presente Trabajo Fin de Máster ha cumplido satisfactoriamente con el objetivo general de desarrollar y validar un sistema de *scoring* bancario avanzado para el mercado español. A través de la integración de técnicas de *machine learning* y herramientas de explicabilidad (XAI), se ha logrado superar las limitaciones de los modelos tradicionales sin sacrificar la transparencia exigida por el regulador financiero.

A continuación, se detallan las conclusiones principales derivadas de la investigación, estructuradas según los objetivos específicos alcanzados:

8.1. Superioridad Analítica y Resolución del Sesgo Geográfico

Eficacia del filtrado y depuración: La metodología de limpieza aplicada permitió transitar de un conjunto de datos masivo y ruidoso a una muestra consolidada de 24.352 registros de alta calidad técnica y relevancia geográfica para España.

Superación del *Concept Drift*: Se ha demostrado empíricamente que el uso de algoritmos genéricos entrenados en otras geografías es ineficiente para el mercado español (AUC del *Benchmark* de 0.4928). El modelo desarrollado ha corregido este sesgo, alcanzando un AUC de 0.7071, lo que certifica su capacidad para ordenar el riesgo de forma precisa en el contexto local.

Valor del *Feature Engineering*: La creación de ratios financieros específicos (PTI, DTI y Margen de Liquidez) resultó ser un factor determinante, aportando un valor analítico superior al de las variables brutas y permitiendo a la Regresión Logística mejorar su rendimiento base.

8.2. Transparencia y Explicabilidad (XAI)

Ruptura de la "Caja Negra": Mediante la implementación de la metodología SHAP, se ha resuelto la opacidad intrínseca de los modelos de Gradient Boosting. Esto garantiza que el algoritmo cumple con los requisitos de los Acuerdos de Basilea y las normativas europeas al permitir auditar cada decisión de crédito de forma individual.

Validación de la Lógica Financiera: La auditoría global confirmó que la Inteligencia Artificial ha interiorizado fundamentos de solvencia robustos. El modelo prioriza correctamente factores como el historial de pagos exitosos, la estabilidad laboral y la capacidad de generación de rentas, rechazando correlaciones espurias y garantizando una operativa ética y coherente.

8.3. Optimización Económica y Rentabilidad de Negocio

Eficiencia de la estrategia de *Risk-Based Pricing*: Se ha demostrado que la transición de una decisión binaria (Aceptar/Denegar) a una estratificación continua por *Ratings* (A-E) permite capturar la rentabilidad de los perfiles *Subprime* de forma controlada.

Maximización del Beneficio Neto: La calibración del umbral operativo en el 26% ha resultado ser la configuración óptima para equilibrar la captura de ingresos por intereses frente a la pérdida esperada. Bajo este umbral, el algoritmo es capaz de absorber un cierto nivel de morosidad gracias al elevado margen del 57,22% que caracteriza a estas operaciones.

Cuantificación del Ahorro: El impacto económico es el resultado más concluyente de este trabajo. El despliegue del modelo CatBoost sobre la cartera de evaluación habría generado un ahorro neto estimado de 2,271,211€. Esta cifra se deriva de la capacidad del sistema para bloquear el 99.1% del capital tóxico (3.3 millones de euros), minimizando a su vez el lucro cesante por el rechazo de clientes solventes.

8.4. Resiliencia ante Escenarios de Crisis (*Stress Testing*)

Capacidad de Cortafuegos Dinámico: Las pruebas de esfuerzo han validado la robustez del modelo ante deterioros del ciclo económico. Ante un escenario de "tormenta perfecta" (caída de ingresos del 20% y aumento de deuda del 15%), el sistema activa automáticamente un bloqueo preventivo masivo.

Sensibilidad Elástica: Se concluye que el modelo no es estático; su sensibilidad le permite detectar cuándo los perfiles que eran aceptables en condiciones normales cruzan la frontera del impago técnico ante una crisis. Esta característica garantiza la supervivencia del capital de la entidad incluso en escenarios de recesión profunda, demostrando ser una herramienta de gestión de riesgos superior a los sistemas de puntuación rígidos.

8.5. Limitaciones del Estudio

A pesar de la robustez de los resultados obtenidos, es preciso reconocer ciertas limitaciones inherentes al diseño de la investigación que deben ser tenidas en cuenta para la interpretación de las conclusiones:

- **Origen y perfil de los datos:** La base de datos empleada proviene de Bondora, una plataforma de financiación alternativa (P2P) especializada en el segmento *subprime*. Por tanto, la capacidad de generalización del modelo a entidades de banca tradicional (donde el perfil de riesgo y el comportamiento del cliente suelen ser más conservadores) podría requerir un ajuste y reentrenamiento sobre carteras con demografías financieras distintas.
- **Sesgo de supervivencia (*survivorship bias*):** El preprocesamiento de los datos exigió la exclusión de las operaciones activas (current loans) para evitar ruido estadístico en las estimaciones a corto plazo. Sin embargo, esta decisión introduce un potencial sesgo de supervivencia en la muestra final, ya que los préstamos solventes de larga maduración permanecen abiertos y activos en los registros históricos de la plataforma, mientras que los activos fallidos cierran de forma prematura por *default*. Esta asimetría tiende a inflar artificialmente la tasa de mora observada en el *dataset*, orientando el aprendizaje del algoritmo hacia la clasificación de operaciones históricamente cerradas en lugar de proyectar un horizonte puro de impagos a 12

meses.

- Estrategia de partición y validación temporal: La división del conjunto de datos se realizó mediante un muestreo aleatorio estándar (*random split*). En el ámbito del *credit scoring* bancario, la práctica regulatoria óptima exige una validación fuera de tiempo (*out-of-time validation*) que separe cronológicamente los años de entrenamiento de los de prueba. Al no aplicar un corte temporal estricto, existe la posibilidad de que el modelo capture patrones macroeconómicos latentes o tendencias de cohorte compartidas entre los conjuntos de datos, por lo que su rendimiento operativo real frente a futuras concesiones de crédito podría diferir sensiblemente de los resultados simulados.
- Ausencia de contrastes estadísticos inferenciales: La evaluación de la superioridad predictiva del algoritmo CatBoost frente a la Regresión Logística se fundamenta en la divergencia matemática de sus métricas absolutas de rendimiento (ROC-AUC). Desde un punto de vista estrictamente estadístico, no se ejecutaron contrastes formales de hipótesis (como la prueba de DeLong) para determinar la significación estadística de la diferencia entre ambas curvas, por lo que dicha superioridad debe interpretarse bajo un criterio analítico de eficiencia operativa y de negocio.
- Naturaleza estática de la simulación: El análisis de impacto económico y las pruebas de esfuerzo (*Stress Testing*) se han realizado bajo un enfoque estático, simulando *shocks* puntuales en las variables financieras del prestatario. En un escenario de crisis real, la interacción entre los factores macroeconómicos, las políticas de recobro y el comportamiento humano es dinámica y multicausal, lo que podría generar efectos de segundo orden no capturados de forma íntegra en esta modelización.
- Dependencia de la calidad del dato original: Como ocurre en cualquier sistema de *machine learning*, la precisión del modelo está supeditada a la veracidad de la información declarada por los solicitantes en el momento de la contratación. Aunque se aplicaron filtros de calidad estrictos, cualquier sesgo sistemático en la recogida de datos original podría impactar en la estabilidad de las predicciones a largo plazo.
- Riesgo de sesgo y equidad algorítmica (*Fairness*): El modelo utiliza como predictores de alto impacto características sociodemográficas como la edad o el nivel educativo. Aunque desde una perspectiva estrictamente matemática estas variables optimizan la rentabilidad, penalizar ciertas cohortes poblacionales puede entrar en conflicto con normativas antidiscriminación como el GDPR (Artículo 22) o la reciente *EU AI Act*, que clasifica el *credit scoring* como sistema de alto riesgo. Sin embargo, el diseño metodológico de este proyecto mitiga esta vulnerabilidad mediante la aplicación intensiva de técnicas de explicabilidad (Valores SHAP). Esta transparencia estructural impide que el modelo opere como un decisor autónomo opaco (caja negra), permitiendo a los analistas de riesgos auditar la contribución exacta de cada variable sociodemográfica y garantizando así la equidad crediticia y el cumplimiento

8.6. Síntesis Final y Valor de la Propuesta

En conclusión, este Trabajo Fin de Máster trasciende la mera aplicación técnica de algoritmos para proponer un cambio de paradigma en la gestión del riesgo de crédito en España. Los resultados obtenidos demuestran que la adopción de modelos de Inteligencia Artificial avanzada no es solo una opción de mejora operativa, sino una necesidad estratégica para garantizar la competitividad y la solvencia de las instituciones financieras en la era del dato. Al haber resuelto con éxito el sesgo de *Concept Drift* y haber alcanzado una capacidad discriminante superior (AUC de 0.7071), este proyecto valida que el conocimiento profundo de la realidad económica local, combinado con arquitecturas de aprendizaje automático, permite optimizar la toma de decisiones allí donde la estadística tradicional resulta insuficiente.

El valor fundamental de la propuesta reside en haber demostrado que la rentabilidad y la ética regulatoria no son conceptos excluyentes. El modelo desarrollado no solo garantiza una mejora drástica en la salud financiera de la entidad (reflejada en un ahorro neto estimado de 2,27 millones de euros), sino que lo hace bajo un marco de transparencia total. La integración de CatBoost como motor de decisión y SHAP como auditor de explicabilidad establece una arquitectura de referencia capaz de "abrir la caja negra" del algoritmo. Esto permite que cada denegación o aprobación de crédito sea plenamente justificable ante los reguladores internacionales y, lo más importante, ante el propio cliente, cumpliendo así con las exigencias de responsabilidad y transparencia que la sociedad actual demanda a la banca.

Finalmente, este trabajo pone de manifiesto que el futuro del sector financiero reside en la capacidad de transformar volúmenes masivos de información en inteligencia accionable y segura. La metodología aquí presentada sienta las bases para una nueva generación de sistemas de *scoring* que son, al mismo tiempo, más precisos, más rentables y dinámicos. En definitiva, este proyecto reafirma el papel del Científico de Datos como una figura clave en la modernización del sistema bancario, capaz de diseñar herramientas que protejan el capital de la institución mientras fomentan una inclusión financiera basada en el análisis objetivo y transparente del riesgo.

Capítulo 9. Trabajos futuros

Los resultados y conclusiones obtenidos en este Trabajo Fin de Máster constituyen una base sólida para la modernización de los sistemas de admisión de riesgos, pero representan únicamente el primer paso hacia una arquitectura de decisión totalmente automatizada e inteligente. Dada la naturaleza dinámica de los mercados financieros y la evolución constante de las técnicas de Ciencia de Datos, y en respuesta directa a las limitaciones identificadas en este estudio, se plantean varias líneas de investigación futuras:

- **Evolución Arquitectónica (*Deep Learning* y *Ensembles*):** En primer lugar, una evolución natural del proyecto consistiría en la exploración de arquitecturas de aprendizaje profundo. Si bien el algoritmo CatBoost ha demostrado una eficacia sobresaliente en el manejo de datos tabulares, la implementación de redes neuronales específicas para el análisis de riesgo podría revelar patrones no lineales aún más sutiles y complejos. Esta línea permitiría la integración de técnicas de *ensemble learning* más sofisticadas para reducir la varianza de las predicciones y mejorar la estabilidad del sistema.
- **Validación *Out-of-Time* y Análisis de Supervivencia:** Para mitigar el sesgo de supervivencia y las limitaciones derivadas del muestreo aleatorio, la siguiente iteración del modelo exige realizar validaciones cronológicas estrictas que separen los periodos de entrenamiento y prueba. Adicionalmente, la implementación de Análisis de Supervivencia (*Survival Analysis*) permitiría aprovechar la información de los créditos activos actualmente excluidos, prediciendo no solo si un cliente entrará en default, sino en qué momento exacto del horizonte temporal del préstamo lo hará.
- **Enriquecimiento del Dato (*Open Banking*):** Para reducir la dependencia de la veracidad de los datos declarados por el cliente, resulta de gran interés el aprovechamiento de la normativa europea PSD2 y el *open banking*. La capacidad de analizar en tiempo real las transacciones bancarias y los flujos de caja reales del solicitante mitigaría el riesgo de fraude y reduciría la incertidumbre en los perfiles *thin file*, proporcionando al algoritmo una "fotografía" financiera dinámica inmanipulable.
- **Equidad Algorítmica Proactiva (*Fairness-Aware Machine Learning*):** Dado el alto impacto de variables sociodemográficas como la edad y el marco regulatorio estricto de la *EU AI Act*, el sistema debe trascender la actual explicabilidad (XAI). Los desarrollos futuros deben integrar metodologías de *fair machine learning*, aplicando penalizaciones matemáticas en la función de pérdida del algoritmo que fuercen al modelo a maximizar su rentabilidad mientras garantiza, de forma proactiva y cuantificable, la no discriminación de cohortes protegidas.
- **Simulaciones Macroeconómicas Dinámicas:** Para superar la naturaleza estática del *stress testing* actual, es imperativo transitar hacia la modelización basada en agentes (*Agent-Based-Modeling*). Esto permitirá simular escenarios de crisis donde la interacción

macroeconómica es dinámica, evaluando cómo el deterioro de un segmento de la cartera provoca efectos de segundo orden y retroalimenta el riesgo sistémico de la entidad en tiempo real.

- Fijación de Precios Dinámica (*Risk-Based Pricing*): Por último, la conjunción de las mejoras predictivas anteriores sentaría las bases para la línea con mayor impacto estratégico: conectar la salida probabilística de CatBoost a un motor de originación dinámico. Esta arquitectura permitiría abandonar las políticas de tipos de interés estandarizados (tramos A-E), calculando en su lugar una prima teórica continua para cada solicitante basada en su pérdida esperada exacta. Esto aseguraría que el coste de la deuda cubra el riesgo extremo en perfiles *subprime*, a la vez que otorga una ventaja competitiva decisiva para captar volumen en el segmento prime mediante ofertas personalizadas y agresivas.

Capítulo 10. Referencias Bibliográficas

- Ariza-Garzón, M. J., Arroyo, J., Caparrini, A., & Segovia-Vargas, M. J. (2020). Explainability of a machine learning grant-scoring model in peer-to-peer lending. *IEEE Access*, 8, 64873-64890.
- Baesens, B., Roesch, D., & Scheule, H. (2016). *Credit Risk Analytics: Measurement Techniques, Applications, and Examples in SAS*. John Wiley & Sons.
- Basel Committee on Banking Supervision. (2010). *Basel III: A global regulatory framework for more resilient banks and banking systems*. Bank for International Settlements.
- Bracke, P., Datta, A., Jung, C., & Sen, S. (2019). Machine learning explainability in finance: an application to default risk analysis. *Bank of England Working Paper No. 816*. <https://www.bankofengland.co.uk/working-paper/2019/machine-learning-explainability-in-finance-an-application-to-default-risk-analysis>
- Brown, I., & Mues, C. (2012). An experimental comparison of classification algorithms for imbalanced credit scoring data sets. *Expert Systems with Applications*, 39(3), 3446-3453.
- Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8), 861-874.
- Hancock, J. T., & Khoshgoftaar, T. M. (2020). CatBoost for big data: an interdisciplinary review. *Journal of Big Data*, 7(1), 1-45.
- Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30.
- Mondal, A., & Shah, S. (2023). Predicting Credit Risk in European P2P Lending: A Case Study of Bondora Using Supervised machine learning Techniques. *International Journal of Machine Learning and Computing*, 13(6).
- Moscatelli, M., Rossi, S., Siviero, L., & Za, L. (2020). Corporate default forecasting with machine learning. *Expert Systems with Applications*, 161, 113567.
- Noriega, J. P., Rivera, L. A., & Herrera, J. A. (2023). Machine learning for Credit Risk Prediction: A Systematic Literature Review. *Data*, 8(11), 1-17.
- Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: unbiased boosting with categorical features. *Advances in neural information processing systems*, 31.
- Serrano-Cinca, C., & Gutiérrez-Nieto, B. (2016). The use of profit scoring as an alternative to credit scoring systems in peer-to-peer (P2P) lending. *Decision Support Systems*, 89, 113-122.

Siddhartha, M. (2021). *Bondora Peer to Peer Lending Loan Data* [Conjunto de datos]. Kaggle. <https://www.kaggle.com/datasets/sid321axn/bondora-peer-to-peer-lending-loan-data>

Siddiqi, N. (2012). *Credit Risk Scorecards: Developing and Implementing Intelligent Credit Scoring*. John Wiley & Sons.

Thomas, L. C., Edelman, D. B., & Crook, J. N. (2002). *Credit Scoring and Its Applications*. SIAM.

Xia, Y., Zhao, J., He, L., Li, Y., & Niu, M. (2018). A novel credit scoring model based on heterogeneous ensemble learning. *Expert Systems with Applications*, 113, 219-231.